

半朴素贝叶斯分类器

AODE

(Averaged One-Dependent Estimator)

判别式模型与生成式模型

- 判别式 (ep. LR) :

$$P(c \mid \mathbf{x})$$

- 生成式 :

$$P(c \mid \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad \longrightarrow \quad P(c \mid \mathbf{x}) = \frac{P(c) P(\mathbf{x} \mid c)}{P(\mathbf{x})}$$

- 贝叶斯分类器属于生成式, 假定样本由某种过程生成, 不同的预设产生了不同的模型

回顾朴素贝叶斯

- 预设：样本各个属性互相独立

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

- $P(c)$ ：被分类为 c 的先验概率
- $P(x_i | c)$ ：被分类为 c 时，属性 x_i 的条件概率
- 训练方式：计数

朴素贝叶斯的训练

显然, 朴素贝叶斯分类器的训练过程就是基于训练集 D 来估计类先验概率 $P(c)$, 并为每个属性估计条件概率 $P(x_i | c)$.

令 D_c 表示训练集 D 中第 c 类样本组成的集合, 若有充足的独立同分布样本, 则可容易地估计出类先验概率

$$P(c) = \frac{|D_c|}{|D|} . \quad (7.16)$$

对离散属性而言, 令 D_{c,x_i} 表示 D_c 中在第 i 个属性上取值为 x_i 的样本组成的集合, 则条件概率 $P(x_i | c)$ 可估计为

$$P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|} . \quad (7.17)$$

对连续属性可考虑概率密度函数, 假定 $p(x_i | c) \sim \mathcal{N}(\mu_{c,i}, \sigma_{c,i}^2)$, 其中 $\mu_{c,i}$ 和 $\sigma_{c,i}^2$ 分别是第 c 类样本在第 i 个属性上取值的均值和方差, 则有

$$p(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp \left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2} \right) . \quad (7.18)$$

示例

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.46	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.36	0.37	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

- $P(\text{青绿} | \text{是}) = 3/8$

- $P(\text{青绿} | \text{否}) = 3/9$

示例

- $P(\text{密度}=0.697 | \text{是}) = \frac{1}{\sqrt{2\pi} \cdot 0.129} \exp\left(-\frac{(0.697-0.574)^2}{2 \cdot 0.129^2}\right)$
- 0.129 & 0.574 : 分类为是的样本, 密度的均值与方差

$$P(\text{好瓜} = \text{是}) \times P_{\text{青绿}|\text{是}} \times P_{\text{蜷缩}|\text{是}} \times P_{\text{浊响}|\text{是}} \times P_{\text{清晰}|\text{是}} \times P_{\text{凹陷}|\text{是}} \\ \times P_{\text{硬滑}|\text{是}} \times p_{\text{密度: 0.697}|\text{是}} \times p_{\text{含糖: 0.460}|\text{是}} \approx 0.038,$$

$$P(\text{好瓜} = \text{否}) \times P_{\text{青绿}|\text{否}} \times P_{\text{蜷缩}|\text{否}} \times P_{\text{浊响}|\text{否}} \times P_{\text{清晰}|\text{否}} \times P_{\text{凹陷}|\text{否}} \\ \times P_{\text{硬滑}|\text{否}} \times p_{\text{密度: 0.697}|\text{否}} \times p_{\text{含糖: 0.460}|\text{否}} \approx 6.80 \times 10^{-5}.$$

朴素贝叶斯的问题

- 假设所有属性互相独立（不符合大多数场景）
- 使用朴素贝叶斯，往往代表「不需要考虑属性间独立性」
- 例：垃圾邮件分类问题，一半的邮件包含「博彩」，一半的邮件包含「发票」。朴素贝叶斯会认为一封邮件同时包含这两个词的概率是0.25（实际上是0）

从朴素贝叶斯到半朴素贝叶斯

- 区别：各维度之间是否有相互依赖信息





图 7.1 朴素贝叶斯与两种半朴素贝叶斯分类器所考虑的属性依赖关系

超父属性 (super-parent)

独依赖估计 (ODE)

- One-dependent Estimator
- 假设每个属性除了分类类别 (c) 以外, 仅依赖一个其他属性

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

$$P(c | \mathbf{x}) \propto P(c) \prod_{i=1}^d P(x_i | c, pa_i)$$


SPODE

- super-parent ODE

观看视频耗时	习题耗时	课程偏好	性别
短	长	理工	男
短	长	理工	男
长	短	文史	男
长	短	文史	女
短	长	理工	女
短	短	文史	女
长	短	文史	女

- 理工课程通常视频耗时短，习题耗时长，文史课程相反

SPODE

- 「课程偏好」这一属性作为超父 (SP)
- 朴素贝叶斯：
 - $P(\text{习题耗时}=\text{长} \mid \text{男}) = 2/3$
- SPODE：
 - $P(\text{习题耗时}=\text{长} \mid \text{理工}, \text{男}) = 1$

AODE

- Averaged One-Dependent Estimator
- Webb, G. 2005 “Not so naïve Bayes: Aggregating one-dependence Estimator”
- 尝试将每个属性作为超父构建SPODE，将有足够训练数据支撑的SPODE集成起来作为最终结果

$$P(c | \mathbf{x}) \propto \sum_{\substack{i=1 \\ |D_{x_i}| \geq m'}}^d P(c, x_i) \prod_{j=1}^d P(x_j | c, x_i), \quad (7.23)$$

其中 D_{x_i} 是在第 i 个属性上取值为 x_i 的样本的集合, m' 为阈值常数. 显然, AODE 需估计 $P(c, x_i)$ 和 $P(x_j | c, x_i)$. 类似式(7.20), 有

$$\hat{P}(c, x_i) = \frac{|D_{c, x_i}| + 1}{|D| + N_i}, \quad (7.24)$$

$$\hat{P}(x_j | c, x_i) = \frac{|D_{c, x_i, x_j}| + 1}{|D_{c, x_i}| + N_j}, \quad (7.25)$$

其中 N_i 是第 i 个属性可能的取值数, D_{c, x_i} 是类别为 c 且在第 i 个属性上取值为 x_i 的样本集合, D_{c, x_i, x_j} 是类别为 c 且在第 i 和第 j 个属性上取值分别为 x_i 和 x_j 的样本集合. 例如, 对西瓜数据集 3.0 有

$$\hat{P}_{\text{是, 浊响}} = \hat{P}(\text{好瓜} = \text{是}, \text{敲声} = \text{浊响}) = \frac{6 + 1}{17 + 3} = 0.350,$$

$$\hat{P}_{\text{凹陷} | \text{是, 浊响}} = \hat{P}(\text{脐部} = \text{凹陷} | \text{好瓜} = \text{是}, \text{敲声} = \text{浊响}) = \frac{3 + 1}{6 + 3} = 0.444.$$

拉普拉斯修正

- 用于平滑——某个属性值在样本中未出现，不进行平滑会将这一属性概率设为0


$$\hat{P}(c, x_i) = \frac{|D_{c, x_i}| + 1}{|D| + N_i},$$
$$\hat{P}(x_j | c, x_i) = \frac{|D_{c, x_i, x_j}| + 1}{|D_{c, x_i}| + N_j}$$

- 如果一个属性值没出现过，它对应的概率将被平滑处理成 $1/N_i$ （ N_i 为这个属性所有可能的取值）

AODE

- 每一项就是一个SPODE

$$P(c | \mathbf{x}) \propto \sum_{\substack{i=1 \\ |D_{x_i}| \geq m'}}^d P(c, x_i) \prod_{j=1}^d P(x_j | c, x_i)$$



(b) SPODE

编程任务

- 编写一个AODE（阈值 m 设为0）
- 支持离散属性、支持连续属性、支持增量学习
- 使用watermelon数据集训练与测试，输出每个样本在是和否两个属性上的估计概率值
- 提交代码与输出结果